

Relatório Prévio: Análise de Microestrutura e Risco de Rede no Ethereum

Grupo 9

27 de Abril de 2026

1. Motivação e Escolha do Problema

A motivação para este estudo reside na relevância do Ethereum como a camada base para o ecossistema de Finanças Descentralizadas (DeFi). Do ponto de vista de gestão de risco e economia quantitativa, a rede Ethereum opera como um mercado vivo onde a volatilidade das taxas (*gas*) e a atividade transacional impactam diretamente a liquidez. O objetivo deste projeto é analisar a “saúde sistêmica” da rede e mapear como métricas de atividade on-chain refletem períodos de estresse e congestionamento.

2. Descrição da Base de Dados

Os dados foram extraídos via SQL do *dataset* público `bigquery-public-data.crypto_ethereum` no Google Cloud BigQuery. A escolha desta base permite acessar eventos on-chain decodificados, dispensando o processamento moroso de logs hexadecimais brutos.

A extração combina **duas janelas complementares** para equilibrar profundidade descritiva e robustez estatística:

- **Tick-by-tick (14 dias, LIMIT 250000)** sobre `transactions` e `blocks` para a análise descritiva e o histograma de bimodalidade. Utilizamos `hash`, `value` (convertido para Ether), `gas_price` (convertido para Gwei) e `transaction_count` como proxy de demanda por espaço no bloco.
- **Barras de 15 minutos agregadas server-side (30 dias)** via `GROUP BY` no BigQuery. Esta amostra de ~2880 observações alimenta o EGARCH, o VAR e o HMM nas seções 6 a 8 — escolha que evita estouro de memória local e mantém o custo dentro do tier gratuito do BigQuery.

3. Objetivos Principais e Relações a serem Estudadas

Durante o desenvolvimento do projeto, buscaremos modelar as seguintes dinâmicas quantitativas: 1. **Modelagem de Risco do Gas:** Analisar a distribuição das taxas de transação e o risco de cauda (*tail risk*) durante choques de volatilidade. 2. **Estresse de Rede e Congestionamento:** Correlacionar a densidade de transações por bloco com os custos marginais de execução na rede. 3. **Mapeamento de Regimes:** Identificar mudanças de regime na rede (operações normais vs. *sell-offs* ou alta especulação).

4. Análise Exploratória Inicial

Os dados foram extraídos e tratados para conversão de unidades financeiras (*Wei* para *Ether* e *Gwei*).

4.1. Estatísticas Descritivas do Custo de Rede

A tabela abaixo sumariza as métricas de base para uma amostra recente. Observa-se uma assimetria evidente no custo do *gas*: a média (0.708 Gwei) é substancialmente maior que a mediana (0.471 Gwei), o que indica que *outliers* de alto custo — comuns em períodos de forte competição no livro de ofertas on-chain — estão

puxando o custo da rede para cima. O volume total financeiro rastreado nesta amostra foi superior a 49 mil ETH.


Média (Gwei)	Mediana (Gwei)	Desvio Padrão	Máximo (Gwei)	Volume Total (ETH)
0.385	0.138	0.515	2.147	277279.8

4.2. Distribuição do Custo de Execução (Risco de Cauda)

O histograma em escala logarítmica revela uma característica crítica da microestrutura do Ethereum atual: uma **distribuição bimodal**. Isso sugere fortemente a existência de dois “regimes de mercado” distintos. Um pico de concentração em taxas mais baixas (uso comum da rede) e um segundo pico claro na extremidade direita, indicando momentos em que algoritmos e provedores de liquidez pagam um prêmio agressivo para priorizar transações em janelas de volatilidade.


Distribuição Logarítmica do Preço do Gas (Gwei)

Evidência de bimodalidade: Dois regimes de custo na rede



4.3. Congestionamento e Densidade de Blocos

Analisando a série temporal do número de transações alocadas por bloco, notamos um regime de certa estabilidade na maior parte da janela, seguido por um choque acentuado de demanda na virada do dia 26 para o dia 27 de Abril. Esse tipo de “pico de estresse” será o foco central da continuidade da nossa análise, visando quantificar a elasticidade da rede perante aumentos bruscos de fluxo de ordens.



5. Microestrutura em Barras de 15 Minutos


Para sustentar a modelagem econométrica nas seções seguintes, agregamos as transações em barras regulares de 15 minutos **diretamente no BigQuery** (`GROUP BY TIMESTAMP_SECONDS(DIV(UNIX_SECONDS(block_timestamp), 900) * 900)`), o que permite estender a janela amostral para 30 dias sem onerar a memória local. Cada barra carrega o gas médio, máximo, mínimo, desvio padrão intra-janela, contagem de transações e volume em ETH — granularidade adequada para capturar volatilidade de curto prazo sem o ruído excessivo do tick-by-tick. Barras com menos de três transações foram descartadas para preservar a estabilidade dos estimadores.

Table 1: Resumo da base agregada em barras de 15 min.

Barras	Gas médio (Gwei)	Gas máx (Gwei)	Volatilidade intra-barra	Tx por barra (mediana)
2784	1.532	369763.9	9.994	7758.5

Gas médio em barras de 15 minutos

Série de trabalho para os modelos econométricos das seções 6 a 8



6. Risco de Cauda: EGARCH e VaR/CVaR


Modelamos a volatilidade condicional do log-retorno de `gas_mean` com um **EGARCH(1,1)** sob distribuição t de Student. A grande vantagem desta especificação empírica é a capacidade de capturar caudas pesadas e comprovar matematicamente o efeito alavancagem reverso característico de redes blockchain ($\gamma_1 > 0$): choques positivos no custo (surto de demanda) geram mais volatilidade condicional do que quedas da mesma magnitude. A partir do desvio condicional σ_t extraímos as métricas de Value at Risk (VaR) e Conditional VaR (CVaR) a 95% para a cauda direita (cenário adverso = encarecimento do gas).

Table 2: Coeficientes estimados do EGARCH(1,1) com inovação t de Student.

Parâmetro	Estimativa
μ	0.0004
ω	-1.0997
α_1	0.1729
β_1	0.4907
γ_1	0.4880
shape	4.2772

Gas médio e bandas de risco (Zoom aplicado na cauda de 95%)

Eixo Y limitado visualmente no 98º percentil para evidenciar a microestrutura padrão




O CVaR consistentemente acima do VaR confirma a presença de eventos extremos de cauda longa: nas piores 5% das barras, a alta esperada do gas é materialmente superior ao próprio limiar de VaR — o gestor de risco precisa dimensionar reservas pelo CVaR, não pelo VaR.

7. Dinâmica Demanda-Custo: VAR e Funções de Resposta ao Impulso

Para mapear o feedback entre demanda da rede (`tx_count`) e custo de execução (log-retorno de `gas_mean`), ajustamos um Vetor Autorregressivo (VAR) bivariado, com lag selecionado por AIC. Choques são identificados pela decomposição de Cholesky com `tx_count` ordenado primeiro — hipótese de que a demanda contemporânea influencia o custo, e não o contrário. Intervalos de confiança de 95% provêm de bootstrap com 200 reamostragens.

Funções de Resposta ao Impulso (95% bootstrap)

VAR bivariado entre demanda da rede e log-retorno do gas



O teste de Causalidade de Granger falhou em rejeitar a hipótese nula ($p\text{-valor} > 0.10$), indicando que o acoplamento estrutural entre demanda e custo se dá de forma majoritariamente contemporânea. A leitura horizontal das Funções de Resposta ao Impulso mostra que a absorção do choque é rápida: a microestrutura da rede precifica o congestionamento quase imediatamente dentro da mesma janela de 15 minutos, havendo pouca defasagem persistente para ser explorada via arbitragem de latência.

8. Detecção de Regimes via Hidden Markov Model

A bimodalidade observada na seção 4.2 é formalizada aqui via um **Hidden Markov Model (HMM)** gaussiano de dois estados ajustado sobre a variável contínua de custo. O estado com maior média condicional é rotulado como **estresse**; o outro, **normal**. O algoritmo de Viterbi realiza a classificação retrospectiva in-sample, atribuindo cada barra de 15 minutos ao regime mais provável de forma retroativa, oferecendo uma categorização robusta sem a necessidade de extrapolações preditivas neste primeiro estágio do estudo.




Table 3: Estatísticas condicionais por regime detectado.

regime	Barras	Proporção	Gas médio (Gwei)	Volatilidade média
normal	1593	57.2%	1.115	6.341
estresse	1191	42.8%	2.090	14.879

9. Síntese e Próximos Passos

As quatro camadas econométricas convergem para uma leitura coerente do mercado de gas no Ethereum. O **EGARCH** quantifica o risco de cauda condicional e comprova o efeito alavancagem reverso, indicando que o **CVaR** domina o **VaR** em janelas de choques de demanda — o que tornaria as reservas de contingência subdimensionadas caso a análise se restringisse apenas ao **VaR**. O **VAR** mapeia que o acoplamento entre demanda e custo possui rápida absorção contemporânea, com atrito precificado majoritariamente dentro da própria janela de 15 minutos. O **HMM**, por fim, classifica retrospectivamente quando o regime estressado esteve ativo, oferecendo uma chave de leitura categórica sobre a série contínua de volatilidade.

A continuidade natural do trabalho passa por: (i) estender o **EGARCH** para especificações multivariadas (**DCC-GARCH**) cruzando gas com volume em **ETH**; (ii) testar **VAR** estrutural com identificação por restrições de sinal; (iii) escalar o **HMM** para três estados (calmaria, normal, estresse) e correlacionar transições com eventos macro (lançamento de protocolos, liquidações).